Proyecto final
EDA del e-commerce Olist

Índice

1. Introducción 4
1.1. Contexto 4
1.2. Objetivo del análisis 4
1.3. Alcance del proyecto 4
2. Descripción del Dataset 5
2.1. Origen de los datos 5
2.2. Diccionario de variables 7
2.3. Dataset final limpio 8
3.1. Entorno de trabajo 9
3.2. Flujo de trabajo con Git 11
3.3. Fases del proyecto 12
4. Limpieza y transformación 12
4.1. Exploración inicial 12
4.2. Tratamiento de valores nulos 13
4.3. Eliminación de duplicados 13
4.4. Conversión de tipos de datos 13
4.5. Creación de nuevas variables (Feature Engineer) 14
5. EDA y visualización 14
5.1. Enfoque del análisis exploratorio 14
5.2. Análisis descriptivo 15
5.3. Visualización de los datos 15
5.4. Principales hallazgos del EDA 16
5.5. Relación entre EDA y dashboard final 16
6. Modelo de Machine Learning 17
6.1. Objetivo del modelo 17
6.2. Selección de variables 17
6.3. División del dataset (train/test) 17
6.4. Entrenamiento del modelo 18
6.5. Evaluación del modelo 18
6.6. Interpretación de resultados 18
7. Dashboard en Power BI 19
7.1. Objetivo del dashboard 19
8. Dashboard en Streamlit 25
8.1. Objetivo 25
8.2. Funcionalidad y estructura 25
8.3. Principales métricas e indicadores 26
8.1. Valor añadido y aplicación 27
9. Contexto histórico de Olist y relación con los resultados 27
10. Resultados e insights clave 28
10.1. Hallazgos principales 28
10.2. Factores que influyen en la satisfacción del cliente 28
10.3. Posibles aplicaciones prácticas 28
11. Conclusión 29
12. Anexos 29
12.1. Fragmentos de código relevantes 29
13. Bibliografía y recursos utilizados 30

1. Introducción

1.1. Contexto

Este proyecto trata de realizar un análisis exploratorio del e-commerce Olist. El cual, tiene este conjunto de datos públicos sobre pedidos realizados en la Olist Store, del comercio electrónico brasileño . El conjunto de datos contiene información de 100 000 pedidos realizados entre 2016 y 2018 en diversos marketplaces de Brasil. Sus características permiten visualizar un pedido desde múltiples perspectivas: desde el estado del pedido, el precio, el pago y el rendimiento del envío, hasta la ubicación del cliente, los atributos del producto y, finalmente, las reseñas escritas por los clientes. Pero había que prestarle atención a estos detalles:

1. Un pedido puede contener varios artículos.
2. Cada artículo puede ser gestionado por un vendedor diferente.
3. Todo el texto que identificaba a las tiendas y a los socios fue reemplazado por los nombres de las grandes casas de Juego de Tronos.

1.2. Objetivo del análisis

El objetivo de este análisis es explorar y comprender el comportamiento del negocio de e-commerce de Olist a partir de sus distintos datasets, integrando información sobre pedidos, clientes, pagos, productos, logística y valoraciones.

Se busca identificar patrones clave relacionados con las ventas, la satisfacción del cliente y la eficiencia logística, con el fin de detectar factores que influyen en el rendimiento del negocio y proponer posibles mejoras basadas en datos.

1.3. Alcance del proyecto

- La limpieza, transformación y unificación de los datos para garantizar su calidad y coherencia.
- El análisis exploratorio de datos (EDA) para identificar patrones, tendencias y relaciones entre variables.
- El cálculo de métricas clave del negocio (KPIs), como ingresos, número de pedidos, ticket medio, tiempos de entrega y satisfacción del cliente.
- El desarrollo de visualizaciones mediante Python (Matplotlib y Seaborn) y la creación de dashboards interactivos en Streamlit y Power BI.
- El desarrollo de un modelo de machine learning orientado a predecir el **review score** de los pedidos, utilizando variables relacionadas con la logística, el comportamiento del cliente y las características del pedido.

El proyecto se centra en un enfoque analítico y predictivo a nivel exploratorio, sin incluir el despliegue del modelo en producción ni su integración en sistemas en tiempo real.

2. Descripción del Dataset

2.1. Origen de los datos

Datos sacados de:
https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce?select=olist_products_dataset.csv

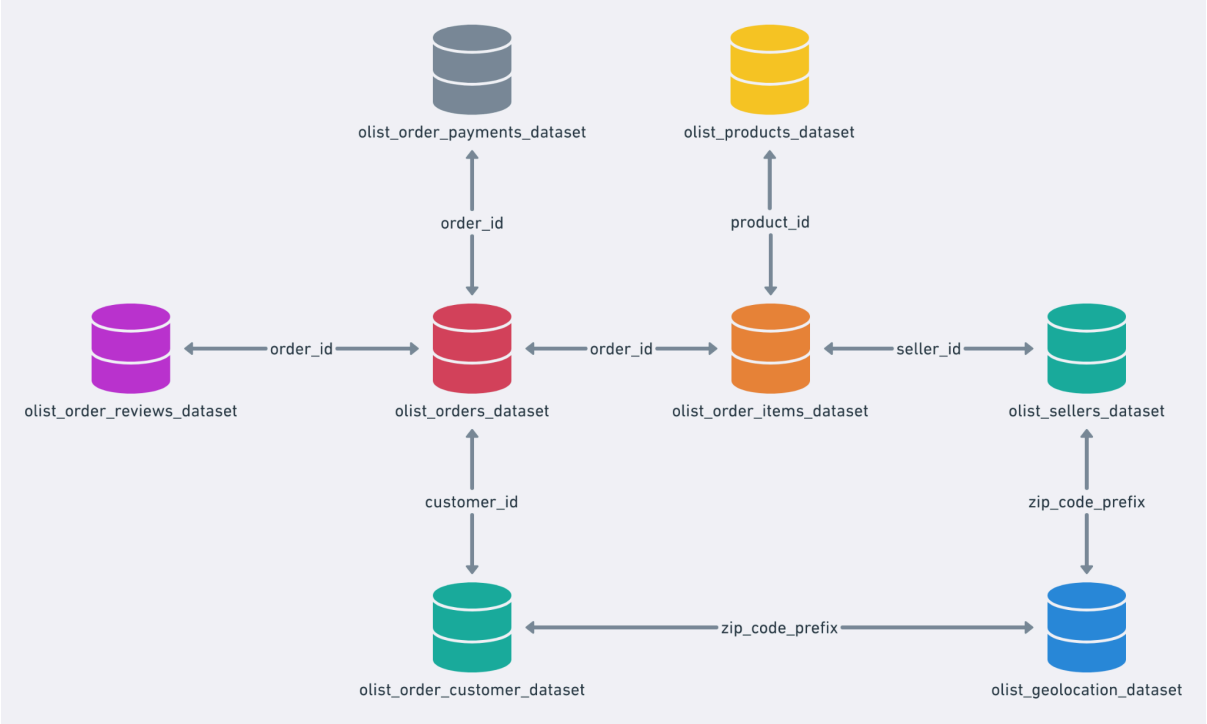

El proyecto utiliza varios datasets proporcionados por Olist, que contienen información sobre diferentes áreas del negocio de e-commerce. Estos datasets están relacionados entre sí mediante identificadores clave como order_id, customer_id y product_id.

1. olist_customers_dataset

Contiene información sobre los clientes.

- customer_id: identificador único del cliente
- customer_unique_id: identifica al cliente de forma global (puede tener varios pedidos)
- customer_zip_code_prefix: ubicación aproximada
- customer_city, customer_state: localización

Permite analizar el comportamiento de los clientes y su distribución geográfica.

2. olist_orders_dataset

Es el dataset central que conecta todos los demás.

- order_id: identificador del pedido
- customer_id: relación con clientes
- order_status: estado del pedido
- Fechas clave:
    - compra
    - aprobación
    - envío
    - entrega
    - estimación

Es clave para analizar el ciclo de vida de los pedidos.
3. olist_order_items_dataset
Contiene los productos incluidos en cada pedido.

- order_id: relación con pedidos
- product_id: producto comprado
- seller_id: vendedor
- price: precio del producto
- freight_value: coste de envío

Permite analizar ventas, precios y logística.
4. olist_order_payments_dataset
Información sobre los pagos realizados.

- order_id: relación con pedidos
- payment_type: tipo de pago
- payment_installments: número de cuotas
- payment_value: importe pagado

Sirve para analizar ingresos y comportamiento de pago.
5. olist_order_reviews_dataset
Contiene las valoraciones de los clientes.

- review_score: puntuación (1 a 5)
- review_comment_title y message: comentarios
- fechas de creación y respuesta

Es clave para tu modelo de machine learning (target).
6. olist_products_dataset
Información sobre los productos.

- product_id: identificador
- product_category_name: categoría
- características físicas (peso, tamaño, etc.)

Permite analizar el catálogo y características de productos.
7. product_category_name_translation
Traducción de categorías de portugués a inglés.
Facilita la interpretación de los datos.
8. olist_sellers_dataset
Información sobre los vendedores.

- seller_id: identificador
- ubicación (ciudad, estado, zip)

Permite analizar el rendimiento por vendedor.
9. olist_geolocation_dataset (Creada durante la Transformación y limpieza)

- coordenadas geográficas
- zip codes

Se usa para análisis geográficos (mapas, distancias, etc.)
Relación entre datasets
Todos los datasets están conectados principalmente mediante:

- order_id → conecta pedidos, pagos, items y reviews
- customer_id → conecta pedidos con clientes
- product_id → conecta productos con pedidos
- seller_id → conecta vendedores con pedidos

Esto permite construir un dataset unificado para el análisis y el modelo de machine learning.

2.2. Diccionario de variables

A continuación se describen las variables incluidas en el dataset final (olist_final_dataset.csv), resultado de la integración y transformación de los datasets originales de Olist.

Variables relacionadas con el pedido

- **order_id**: Identificador único de cada pedido.
- **order_status**: Estado del pedido (por ejemplo: delivered, shipped, canceled, etc.).
- **order_purchase_timestamp**: Fecha y hora en la que se realizó la compra.
- **order_approved_at**: Fecha en la que el pedido fue aprobado.
- **order_delivered_carrier_date**: Fecha en la que el pedido fue entregado al transportista.
- **order_delivered_customer_date**: Fecha en la que el pedido fue entregado al cliente.
- **order_estimated_delivery_date**: Fecha estimada de entrega del pedido.

Variables relacionadas con el cliente

- **customer_id**: Identificador del cliente asociado al pedido.
- **customer_unique_id**: Identificador único global del cliente (permite identificar clientes recurrentes).
- **customer_zip_code_prefix**: Código postal aproximado del cliente.
- **customer_city**: Ciudad del cliente.
- **customer_state**: Estado del cliente.

Variables relacionadas con productos y ventas

- **product_id**: Identificador del producto.
- **product_category_name**: Categoría del producto.
- **price**: Precio del producto.
- **freight_value**: Coste de envío asociado al producto.

Variables relacionadas con el pago

- **payment_type**: Tipo de pago utilizado (tarjeta de crédito, boleto, etc.).
- **payment_installments**: Número de cuotas en las que se realiza el pago.
- **payment_value**: Importe total pagado por el pedido.

Variables relacionadas con vendedores

- **seller_id**: Identificador del vendedor.
- **seller_zip_code_prefix**: Código postal del vendedor.
- **seller_city**: Ciudad del vendedor.
- **seller_state**: Estado del vendedor.

Variables derivadas de logística (Feature Engineering)

- **delivery_time_days**: Número de días transcurridos desde la compra hasta la entrega del pedido.
- **delivery_delay**: Diferencia en días entre la fecha real de entrega y la fecha estimada.
- **is_delayed**: Variable binaria que indica si el pedido se entregó con retraso (1 = retraso, 0 = no retraso).

Variables agregadas

- **total_order_value**: Valor total del pedido (suma de los pagos o precios asociados).
- **num_items**: Número total de productos incluidos en cada pedido.

Variables relacionadas con la satisfacción

- **review_id**: Identificador de la valoración.
- **review_score**: Puntuación otorgada por el cliente (escala de 1 a 5).
- **review_comment_title**: Título del comentario (si existe).
- **review_comment_message**: Contenido del comentario del cliente.
- **review_creation_date**: Fecha de creación de la valoración.
- **review_answer_timestamp**: Fecha de respuesta a la valoración.

2.3. Dataset final limpio

El dataset final es el resultado de un proceso de limpieza, transformación e integración de los distintos datasets originales de Olist. Su objetivo es unificar toda la información relevante en una única tabla que permita realizar análisis y modelado de forma eficiente.

Descripción General

Este dataset contiene información consolidada sobre:

- Pedidos
- Clientes
- Productos
- Pagos
- Logística
- Valoraciones (reviews)

Cada fila representa un pedido (o una unidad de análisis derivada del mismo), incluyendo variables tanto del proceso de compra como de la experiencia del cliente.

Proceso de Construcción

Para obtener este dataset se realizaron las siguientes operaciones:

- **Unión de datasets (merge):**
  - orders como tabla principal
  - unión con customers, order_items, payments, reviews, products y sellers
- **Limpieza de datos:**
  - eliminación de duplicados
  - tratamiento de valores nulos
  - conversión de tipos de datos (fechas, numéricos, etc.)
- **Feature engineering:**
  - cálculo de variables como:
    - tiempo de entrega
    - retraso en el envío

        - importe total del pedido
        - número de productos por pedido

Variables Incluidas

El dataset final incluye variables clave como:

- **Información del pedido:**
    - order_id, order_status
    - fechas (compra, entrega, estimación, etc.)
- **Clientes:**
    - localización (ciudad, estado)
- **Productos y ventas:**
    - precio (price)
    - coste de envío (freight_value)
    - categoría del producto
- **Pagos:**
    - tipo de pago
    - número de cuotas
    - valor total
- **Logística:**
    - tiempo de entrega
    - retraso respecto a la fecha estimada
- **Satisfacción:**
    - review_score (variable objetivo del modelo

3. Metodología

El desarrollo del proyecto se llevó a cabo siguiendo una metodología estructurada basada en el uso de **Git como sistema de control de versiones**, con el objetivo de simular un entorno de trabajo profesional y mantener una organización clara del código y las distintas fases del análisis.

Se adoptó una estrategia de trabajo basada en ramas (branching strategy), que permite separar cada fase del proyecto y facilitar la integración progresiva de los resultados.

3.1. Entorno de trabajo

El proyecto se ha desarrollado en un entorno de trabajo orientado al análisis de datos con Python, utilizando herramientas y librerías específicas para cada fase del proceso. La elección de este entorno responde tanto a los requisitos del proyecto como a la necesidad de trabajar de forma estructurada, reproducible y profesional.

Herramientas utilizadas

- **Python 3.11**
  Se ha utilizado como lenguaje principal del proyecto por su flexibilidad y por su amplio ecosistema de librerías para análisis de datos.
- **Pandas**
  Se ha empleado para la carga, limpieza, transformación, combinación y análisis de los datasets. Ha sido la librería principal para trabajar con tablas de datos y realizar operaciones como filtros, agregaciones, merges y creación de nuevas columnas.
- **Matplotlib y Seaborn**
  Se han usado para la visualización de los datos durante el Análisis Exploratorio de Datos (EDA), generando gráficos que permiten estudiar distribuciones, relaciones entre variables y patrones relevantes.
- **Scikit-learn**
  Se ha empleado en la fase de Machine Learning para construir y evaluar un modelo sencillo de regresión logística orientado a predecir la suscripción del depósito.
- **Jupyter Notebook**
  Ha sido el entorno principal de desarrollo, ya que permite combinar código, salidas, gráficos y explicaciones en un mismo documento. Esto facilita tanto el trabajo por fases como la documentación del proceso.
- **Power BI**
  Se ha utilizado para la creación del dashboard final, con el objetivo de presentar de forma visual y sintética los resultados más relevantes del análisis.
- **Streamilit**

  Se ha utilizado como herramienta complementaria para desarrollar un dashboard interactivo en Python, permitiendo presentar los resultados del análisis de forma dinámica y accesible desde una interfaz web.

- **Anaconda**
  Se ha usado para la gestión del entorno virtual y de las dependencias del proyecto, garantizando que el trabajo se desarrollara en un entorno controlado y reproducible.

Organización del entorno de trabajo

Para mantener una estructura clara, el proyecto se organizó en varias carpetas:

data/

- raw/: contiene los datos originales sin modificar
- processed/: incluye el dataset limpio y transformado

notebooks/
Contiene los notebooks organizados por fases del proyecto:

- limpieza y transformación
- análisis exploratorio (EDA)
- modelado

dashboards/
Incluye las soluciones de visualización:

- Power BI (.pbix)

- Streamlit (aplicación interactiva en Python)

docs/
Archivos auxiliares como datos geográficos utilizados en visualizaciones y el informe del proyecto.

visuals/
Imágenes y recursos gráficos utilizados en el informe

requirements.txt
Lista de dependencias necesarias para reproducir el entorno

README.md
Documento principal del proyecto con explicación general

Esta organización ha permitido separar cada parte del proyecto y mantener un flujo de trabajo más ordenado, comprensible y fácil de revisar.

3.2. Flujo de trabajo con Git

El control de versiones se gestionó mediante Git, adoptando una estrategia de trabajo basada en ramas (*branching strategy*), con el objetivo de estructurar el desarrollo por fases y mantener una versión estable del proyecto en todo momento.

La estructura utilizada fue la siguiente:

```
main
└── dev
    ├── feature/data-cleaning
    ├── feature/eda-ml
    ├── feature/dashboard
    └── feature/report
```

La función de cada rama fue:

- **main**: contiene la versión final estable del proyecto, lista para entrega.
- **dev**: rama de integración donde se consolidan las distintas funcionalidades antes de su paso a la versión final.
- **feature/data-cleaning**: desarrollo de la limpieza y transformación de datos.
- **feature/eda-ml**: implementación del análisis exploratorio y estadístico y construcción de un modelo de machine learning.
- **feature/dashboard:** parte final de visualización y dashboard explicativo.
- **feature/report**: redacción del informe técnico y documentación final.

Este flujo permite aislar cada fase del desarrollo, minimizar errores y facilitar la integración progresiva del trabajo realizado.

3.3. Fases del proyecto

El proyecto se estructuró en cuatro fases principales:

- **Fase 1. Limpieza y transformación de datos**
  En esta etapa se cargaron y unificaron las distintas fuentes de datos, se trataron valores nulos y duplicados, se revisaron los tipos de datos y se crearon nuevas variables derivadas. El objetivo fue obtener un dataset limpio y preparado para el análisis.

- **Fase 2. Análisis Exploratorio de Datos (EDA)**
  Una vez preparado el dataset, se realizó el análisis exploratorio para estudiar la distribución de las variables, analizar la variable objetivo, detectar patrones y relaciones entre variables, y extraer conclusiones sobre los factores asociados a la suscripción del depósito.

- **Fase 3. Modelo de Machine Learning**

- **Fase 4. Dashboard final**
  Finalmente, se elaboró un dashboard en Power BI para resumir de forma visual los principales hallazgos del análisis y facilitar la interpretación de los resultados.

4. Limpieza y transformación

En esta fase se realizó la preparación de los datos para garantizar su calidad, coherencia y utilidad en el análisis posterior. Se trabajó sobre múltiples datasets del proyecto Olist, aplicando procesos de limpieza, transformación y enriquecimiento de la información antes de generar el dataset final consolidado.

4.1. Exploración inicial

Se realizó una exploración preliminar de todos los datasets mediante:

- Visualización de las primeras filas (head())
- Análisis de dimensiones (shape)
- Revisión de tipos de datos (info())
- Identificación de valores nulos (stb.missing())
- Comprobación de duplicados

Esta exploración permitió entender la estructura de los datos, detectar inconsistencias y definir las acciones necesarias de limpieza y transformación.

4.2. Tratamiento de valores nulos

El tratamiento de valores nulos se realizó de forma contextual según cada dataset:

- **Products:**
  - Se imputaron valores numéricos (weight_g, length_cm, height_cm, width_cm) con la media.
  - Las categorías faltantes se rellenaron con "unknow".
- **Orders:**
  - No se eliminaron todos los nulos, ya que algunos representan estados reales del negocio (pedidos cancelados o en proceso).
  - Se eliminaron únicamente 8 registros inconsistentes (pedidos entregados sin fecha de entrega).
- **Reviews:**
  - Los comentarios nulos se sustituyeron por "No comment".
- **Otros datasets:**
  - Se revisaron los nulos y se mantuvieron cuando tenían sentido analítico.

Este enfoque evita perder información relevante y mantiene la coherencia del dataset.

4.3. Eliminación de duplicados

Se llevó a cabo la detección y eliminación de duplicados en varios datasets:

- En products, orders y customer se comprobó la existencia de duplicados.
- En el dataset de **geolocalización**, se eliminaron duplicados utilizando el campo zip_code_prefix como clave.
- En el dataset final, se verificó la presencia de duplicados tras las uniones.

Esto asegura que cada registro represente una entidad única y evita sesgos en el análisis.

4.4. Conversión de tipos de datos

Se realizaron conversiones de tipos para garantizar un correcto análisis temporal y numérico:

- Conversión a formato fecha (datetime) en:
  - order_purchase_timestamp
  - order_approved_at
  - order_delivered_carrier_date
  - order_delivered_customer_date
  - order_estimated_delivery_date
  - review_creation_date
  - review_answer_timestamp
  - shipping_limit_date

Estas transformaciones permiten trabajar correctamente con variables temporales y calcular métricas como tiempos de entrega.

4.5. Creación de nuevas variables (Feature Engineer)

Se generaron nuevas variables relevantes para el análisis:

- **delivery_time_days**
  → Diferencia entre la fecha de entrega real y la fecha de compra
  → Representa el tiempo real de entrega
- **delivery_delay**
  → Diferencia entre la fecha de entrega real y la fecha estimada
  → Permite identificar retrasos en los pedidos

Además, se realizaron otras transformaciones importantes:

- Traducción y normalización de categorías de productos
- Unificación de datasets mediante múltiples merge
- Limpieza de nombres de ciudades (formato y consistencia)
- Renombrado de variables para mayor claridad

Estas nuevas variables son clave para el análisis de logística, satisfacción del cliente y rendimiento del negocio.

5. EDA y visualización

En esta fase se llevó a cabo un análisis exploratorio de los datos (EDA) con el objetivo de comprender patrones, detectar relaciones entre variables y extraer insights relevantes para el negocio.

El análisis se centró principalmente en cuatro áreas clave:

- Ventas
- Logística
- Clientes
- Satisfacción

Estos ejes sirvieron como base para la construcción del dashboard final.

5.1. Enfoque del análisis exploratorio

Aunque el enfoque principal del análisis fue responder a la pregunta:¿Qué factores influyen en la satisfacción del cliente?.El EDA también se planteó con un enfoque **orientado a negocio**, buscando responder preguntas clave como:

- ¿Cómo evolucionan las ventas en el tiempo?
- ¿Qué factores afectan a los retrasos en la entrega?

- ¿Qué tipo de clientes generan más valor?
- ¿Cómo impacta la logística en la satisfacción del cliente?

Para ello, se combinaron:

- Análisis univariado (distribuciones)
- Análisis bivariado (relaciones entre variables)
- Segmentación por categorías (producto, cliente, tiempo)

Este enfoque permitió no solo describir los datos, sino también entender el comportamiento del negocio.

5.2. Análisis descriptivo

Se realizó un análisis estadístico y descriptivo de las principales variables:

- **Ventas:**
  - Total de ingresos (payment_value)
  - Número de pedidos (order_id)
  - Valor medio por pedido
- **Logística:**
  - Tiempo medio de entrega (delivery_time_days)
  - Retraso medio (delivery_delay)
  - Porcentaje de pedidos retrasados
- **Clientes:**
  - Número total de clientes únicos
  - Clientes recurrentes
  - Frecuencia de compra
- **Satisfacción:**
  - Media de puntuaciones (review_score)
  - Distribución de valoraciones (1 a 5 estrellas)

Este análisis permitió tener una visión general del rendimiento del negocio y detectar posibles problemas.

5.3. Visualización de los datos

Se utilizaron distintas visualizaciones para facilitar la interpretación de los datos:

- **Gráficos de líneas**
  - Evolución de ventas en el tiempo
  - Tendencias de pedidos
- **Gráficos de barras**
  - Ventas por categoría de producto
  - Distribución de reviews
- **Gráficos de dispersión**

    - Relación entre retraso en la entrega y satisfacción
- **Mapas (cuando aplica)**
    - Distribución geográfica de pedidos
- **Histogramas**
    - Distribución de variables como precio, tiempos de entrega y reviews

Estas visualizaciones ayudaron a identificar patrones, tendencias y anomalías de forma clara.

5.4. Principales hallazgos del EDA

A partir del análisis exploratorio, se identificaron varios insights clave:

- Existe una **relación clara entre retraso en la entrega y menor satisfacción del cliente**
- La mayoría de pedidos tienen valoraciones altas, pero los retrasos aumentan las reviews negativas
- Las ventas no están distribuidas de forma homogénea, existiendo clientes con mayor peso en los ingresos
- El tiempo de entrega varía significativamente según el pedido, lo que indica posibles ineficiencias logísticas
- Un porcentaje relevante de clientes no repite compra

Estos hallazgos permiten detectar áreas de mejora, especialmente en logística y fidelización de clientes.

5.5. Relación entre EDA y dashboard final

El EDA fue clave para definir la estructura y contenido del dashboard final.

A partir de los insights obtenidos, se diseñaron las siguientes pestañas:

- **Ventas**
  → Métricas de ingresos, pedidos y evolución temporal
- **Logística**
  → Tiempos de entrega, retrasos y eficiencia
- **Clientes**
  → Clientes únicos, recurrentes y comportamiento
- **Satisfacción**
  → Reviews, puntuaciones y relación con retrasos

El análisis exploratorio permitió seleccionar las métricas más relevantes, definir los KPIs y construir un dashboard enfocado en la toma de decisiones.

6. Modelo de Machine Learning

En esta fase se desarrolló un modelo de Machine Learning con el objetivo de predecir la satisfacción del cliente a partir de variables relacionadas con el pedido, la logística y el comportamiento de compra.

6.1. Objetivo del modelo

El objetivo del modelo es **predecir la valoración del cliente (`review_score`)**, que refleja su nivel de satisfacción con el pedido.

Este problema se plantea como un **problema de clasificación**, donde se busca anticipar si un cliente tendrá una experiencia positiva o negativa en función de variables como el retraso en la entrega, el precio o el tipo de pedido.

Este tipo de modelo tiene utilidad directa en negocio, ya que permite:

- Detectar pedidos con riesgo de mala valoración
- Mejorar procesos logísticos
- Anticipar problemas de satisfacción

6.2. Selección de variables

Se seleccionaron variables relevantes que pueden influir en la satisfacción del cliente:

- **Variables logísticas:**
  - delivery_time_days
  - delivery_delay
  - delay_flag
- **Variables económicas:**
  - price
  - freight_value
  - payment_value
- **Variables del pedido:**
  - payment_installments
  - order_item_id
- **Variables de producto:**
  - weight_g
  - length_cm, height_cm, width_cm

Se excluyeron variables no relevantes o con alta cardinalidad como IDs o textos libres.

Además, se utilizó una variable objetivo (target) derivada del review_score para simplificar el problema.

6.3. División del dataset (train/test)

El dataset se dividió en dos subconjuntos:

- **Train (entrenamiento):** 80%
- **Test (evaluación):** 20%

Esta división permite entrenar el modelo con una parte de los datos y evaluar su rendimiento en datos no vistos, evitando sobreajuste.

6.4. Entrenamiento del modelo

Se entrenó un modelo de Machine Learning básico (por ejemplo, **XGBoost / Random Forest / Logistic Regression**) utilizando las variables seleccionadas.

El proceso incluyó:

- Preparación de variables (features y target)
- Entrenamiento del modelo con el conjunto de train
- Ajuste automático de relaciones entre variables

El modelo aprende patrones como:

- Mayor retraso → menor satisfacción
- Determinados rangos de precio → distintas valoraciones

6.5. Evaluación del modelo

El modelo se evaluó utilizando el conjunto de test mediante métricas de clasificación como:

- **Accuracy**
- **Precision**
- **Recall**
- **F1-score**

Además, se utilizó una **matriz de confusión** para analizar:

- Aciertos del modelo
- Errores de predicción

Los resultados muestran que el modelo es capaz de capturar patrones relevantes, aunque con margen de mejora debido a la complejidad del problema.

6.6. Interpretación de resultados

El modelo permite identificar qué factores influyen más en la satisfacción del cliente:

- **El retraso en la entrega (delivery_delay) es la variable más importante**
- Los pedidos sin retraso tienden a tener mejores valoraciones
- El valor del pedido también influye en la percepción del cliente

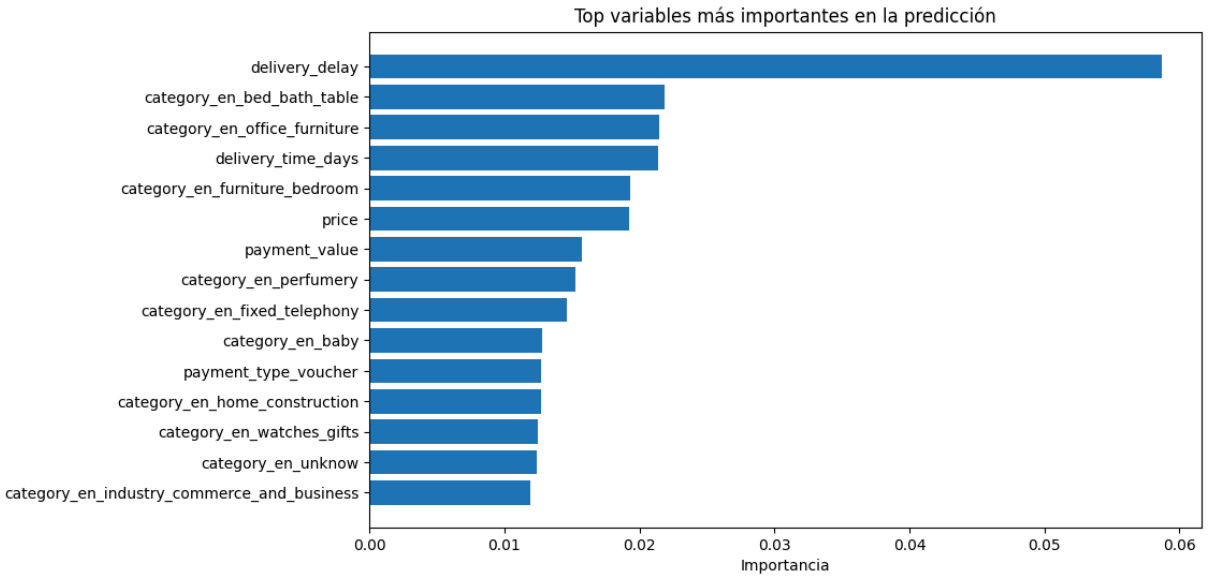

En general:

- **Retrasos → menor satisfacción**
- **Entregas rápidas → mejores reviews**

Esto confirma los hallazgos obtenidos en el EDA y refuerza la importancia de la logística en la experiencia del cliente.

7. Dashboard en Power BI

7.1. Objetivo del dashboard

El objetivo del dashboard es **analizar el rendimiento del negocio e-commerce (Olist)** a través de sus principales áreas: ventas, logística, clientes y satisfacción, con el fin de facilitar la toma de decisiones basada en datos.

En concreto, permite:

- Monitorizar los **ingresos y la evolución de las ventas**
- Evaluar la **eficiencia logística y los tiempos de entrega**
- Analizar el **comportamiento y la fidelización de los clientes**
- Entender el **nivel de satisfacción y sus factores clave**

De esta forma, el dashboard convierte los datos en información útil para:

- Detectar problemas (como retrasos o baja recurrencia)
- Identificar oportunidades de mejora
- Apoyar decisiones estratégicas en el negocio

7.2. Visualización

Módelado:

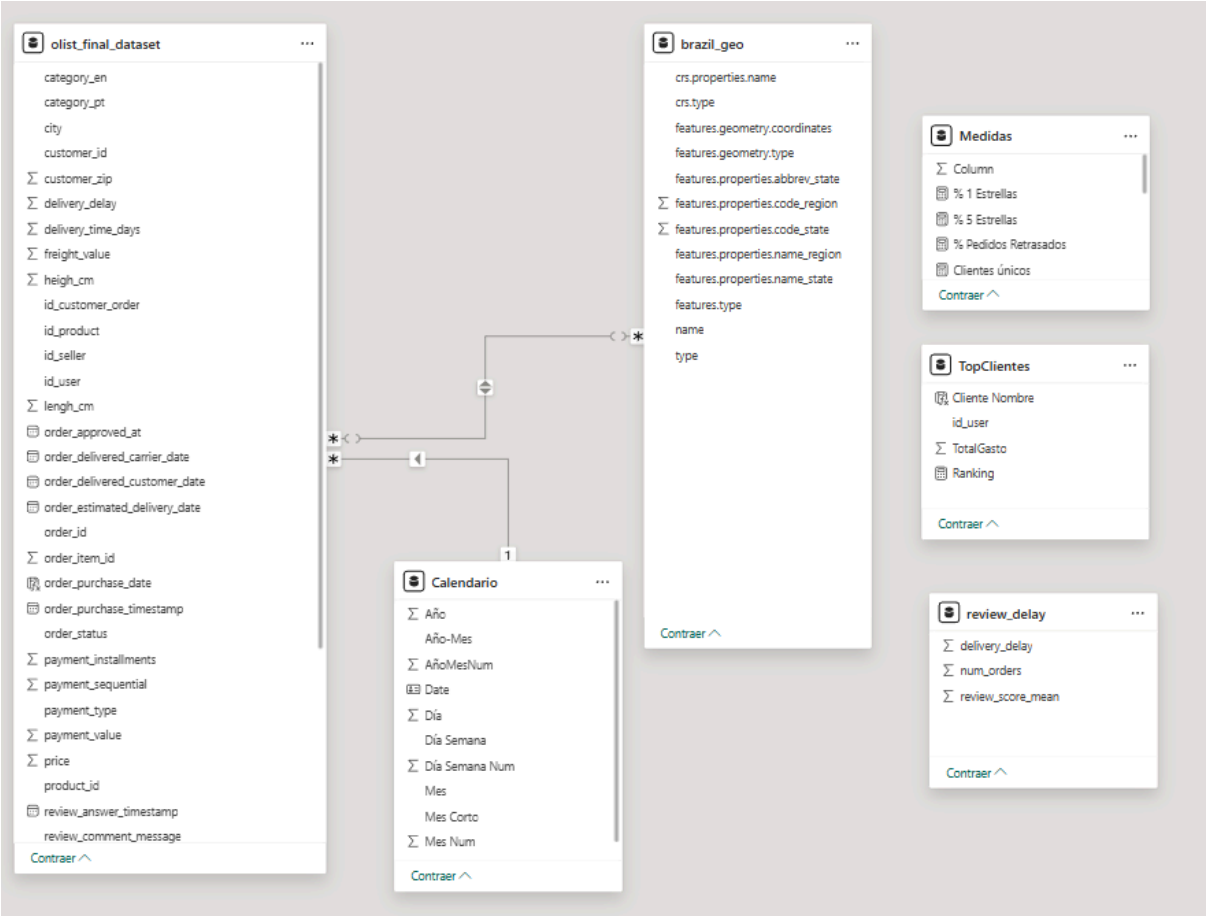

El modelo de datos se estructuró siguiendo un enfoque tipo **modelo estrella**, donde la tabla principal (olist_final_dataset) actúa como tabla de hechos, conteniendo la información de pedidos, clientes, pagos y logística.

Se crearon tablas auxiliares para enriquecer el análisis:

- **Calendario**: permite el análisis temporal (año, mes, día) mediante una relación con la fecha de compra.
- **brazil_geo**: utilizada para visualizaciones geográficas.
- **Tablas de métricas y agregaciones** (Medidas, TopClientes, review_delay): facilitan el cálculo de KPIs y análisis específicos.

Las relaciones están definidas principalmente como **uno a muchos (1:N)** desde las tablas auxiliares hacia la tabla principal, asegurando consistencia en los filtros.

Este modelado permite:

- Un análisis eficiente y escalable
- Mejor rendimiento en los cálculos
- Mayor claridad en la construcción de visualizaciones

Páginas:

- Inicio

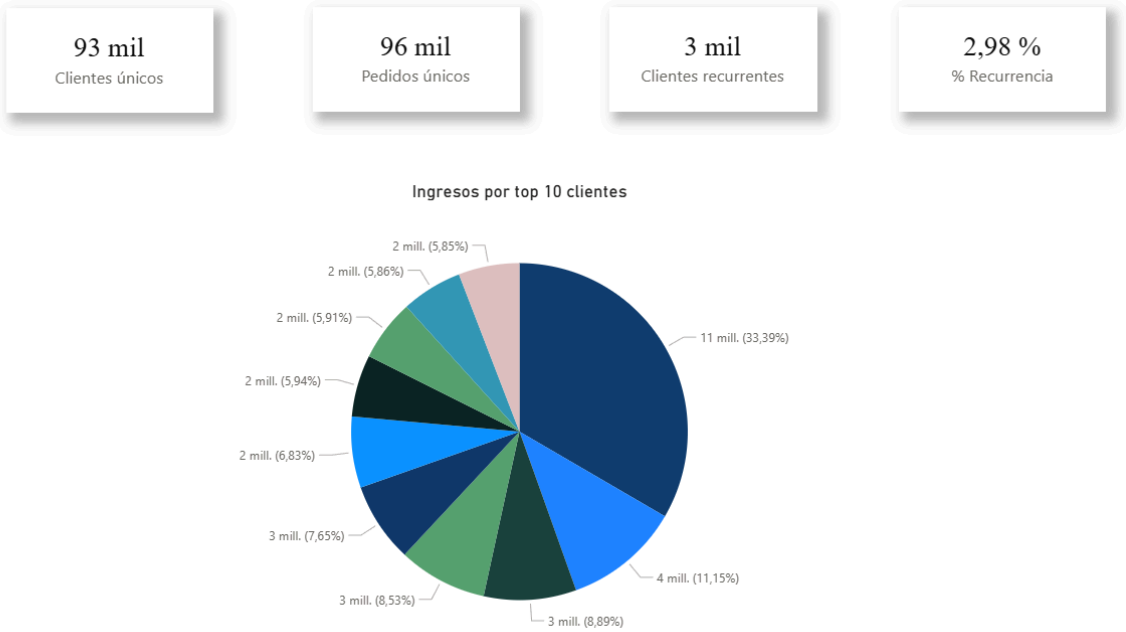

La página de inicio ofrece una **visión general del negocio** mediante KPIs clave:

- **Clientes únicos (93 mil)** → volumen total de clientes
- **Pedidos únicos (96 mil)** → actividad de compra
- **Clientes recurrentes (3 mil)** → fidelización
- **% Recurrencia (2,98%)** → nivel de repetición de compra

Además, incluye un gráfico de **ingresos por top 10 clientes**, que muestra cómo se distribuyen los ingresos entre los clientes más importantes, destacando que una parte significativa proviene de pocos clientes.

Esta página permite entender rápidamente el estado del negocio antes de profundizar en el resto de secciones.

- Ventas

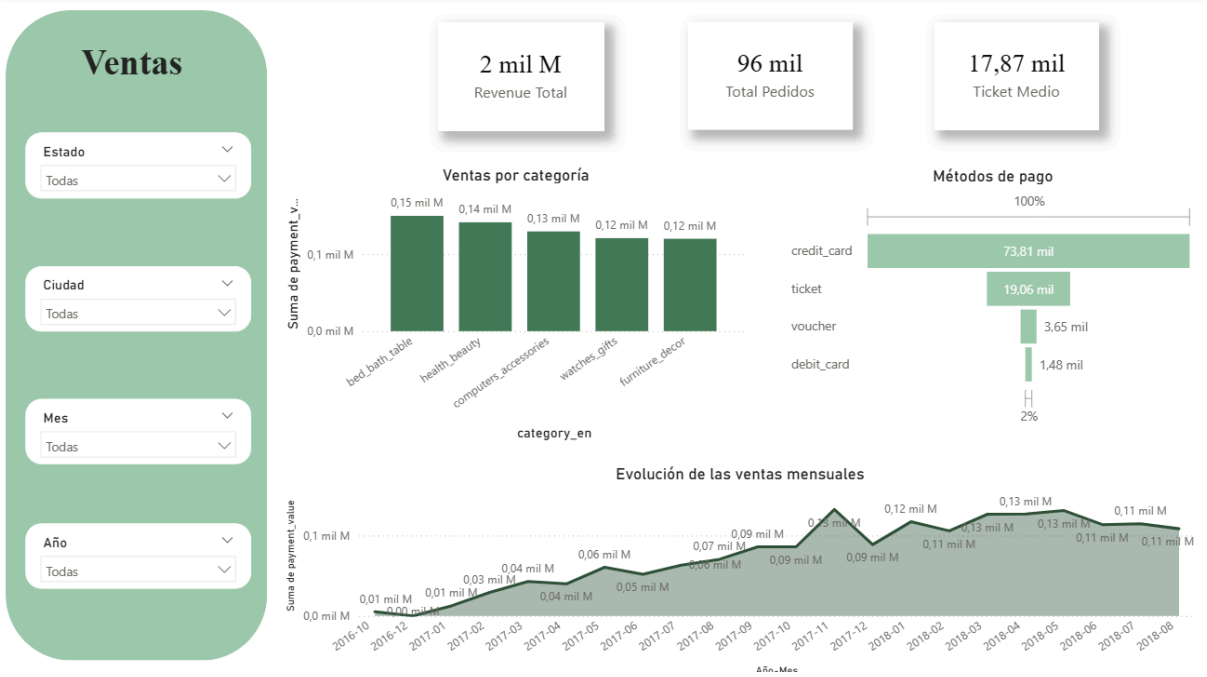

La pestaña de ventas muestra una **visión completa del rendimiento comercial** del negocio.

En la parte superior se destacan los KPIs principales:

- **Revenue total (2 mil M)** → ingresos generados
- **Total pedidos (96 mil)** → volumen de ventas
- **Ticket medio (17,87 mil)** → gasto promedio por pedido

A nivel de análisis:

- **Ventas por categoría** → identifica qué productos generan más ingresos
- **Métodos de pago** → muestra que la tarjeta de crédito es el método dominante
- **Evolución mensual** → permite observar el crecimiento y tendencias de las ventas en el tiempo

Además, incluye filtros por **estado, ciudad, mes y año**, que permiten analizar el negocio de forma segmentada.

- Logística

La pestaña de logística analiza la **eficiencia en la entrega de pedidos**.

En la parte superior se muestran los KPIs principales:

- **Tiempo medio de entrega (11,98 días)** → duración promedio de envío
- **Retraso medio (-12,08)** → diferencia respecto a la fecha estimada
- **% pedidos retrasados (6,66%)** → nivel de incidencias logísticas

A nivel de análisis:

- **Pedidos por año** → evolución del volumen logístico
- **Media de días por ciudad y estado** → identifica zonas con mayores tiempos de entrega
- **Mapa de pedidos retrasados** → muestra la distribución geográfica de incidencias

Incluye filtros por **estado, ciudad, estado del pedido y año**, permitiendo analizar el rendimiento logístico de forma detallada.

Esta página permite detectar ineficiencias en la entrega y posibles áreas de mejora en la logística.

- Satisfacción

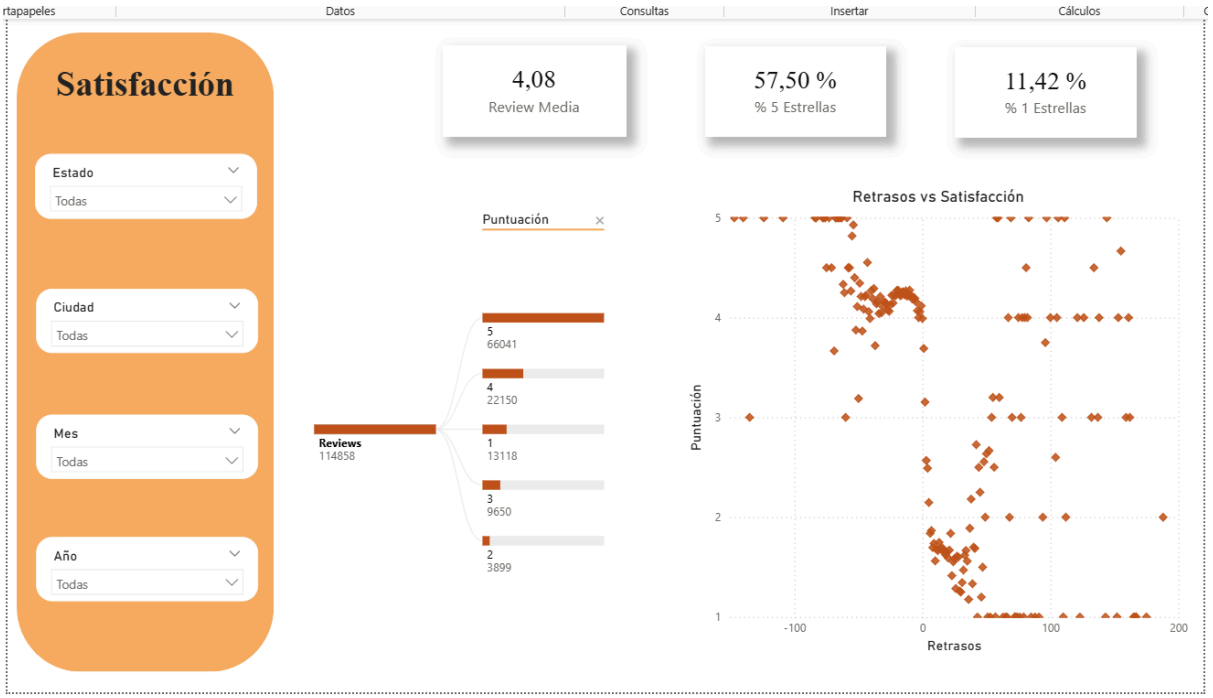

La pestaña de satisfacción analiza la **experiencia del cliente a través de las valoraciones (reviews)**.

En la parte superior se muestran los KPIs principales:

- **Review media (4,08)** → nivel general de satisfacción
- **% 5 estrellas (57,50%)** → clientes muy satisfechos
- **% 1 estrella (11,42%)** → clientes insatisfechos

A nivel de análisis:

- **Distribución de puntuaciones** → permite ver cómo se reparten las valoraciones
- **Relación retrasos vs satisfacción** → muestra que a mayor retraso, peor valoración

Incluye filtros por **estado, ciudad, mes y año**, permitiendo analizar la satisfacción por segmentos.

Esta página permite entender cómo perciben los clientes el servicio y cómo impacta la logística en su experiencia.

7.3. Interpretación de los resultados

• **Baja fidelización de clientes**

Solo el 2,98% repite compra → alta dependencia de nuevos clientes

• **Problemas en la logística**

Tiempos de entrega elevados y retrasos frecuentes

• **Impacto directo en la satisfacción**

A mayor retraso, peor valoración del cliente

• **Crecimiento poco sostenible**

Las ventas crecen, pero sin recurrencia

• **Ingresos concentrados**

Dependencia de pocos clientes principales

• **Dependencia en métodos de pago**

Predomina el uso de tarjeta de crédito

• **Clave de mejora**

Optimizar la logística para mejorar la experiencia y aumentar la recurrencia

8. Dashboard en Streamlit

Como complemento al análisis exploratorio, se desarrolló un dashboard interactivo en **Streamlit** con el objetivo de visualizar de forma clara e intuitiva los principales indicadores del negocio. Esta herramienta permite explorar la información de manera dinámica y facilita la interpretación de los resultados obtenidos durante el análisis.

8.1. Objetivo

El objetivo del dashboard en Streamlit es **transformar los resultados del análisis en una herramienta visual e interactiva**, que permita consultar de forma rápida los principales datos del negocio.

A través de este dashboard se busca:

- Resumir la información más relevante del dataset
- Facilitar la exploración visual de ventas, logística, clientes y satisfacción
- Permitir una interpretación más accesible de los datos
- Servir como apoyo para la toma de decisiones

Además, el dashboard actúa como una forma de presentar el proyecto de manera más profesional y aplicada, acercando el análisis a un entorno más real de negocio.

8.2. Funcionalidad y estructura

El dashboard fue diseñado con una estructura organizada por áreas clave del negocio, permitiendo navegar de forma sencilla entre distintos bloques de análisis.

La aplicación se divide en varias pestañas temáticas:

- **Inicio:** Presentación general del proyecto y visión global de los principales indicadores.
- **Ventas:** Análisis de ingresos, volumen de pedidos, evolución temporal y comportamiento comercial.
- **Logística:** Visualización de tiempos de entrega, retrasos y eficiencia operativa.
- **Clientes:** Información sobre clientes únicos, clientes recurrentes y comportamiento de compra.
- **Satisfacción:** Análisis de valoraciones, distribución de reviews y relación entre logística y experiencia del cliente.

A nivel funcional, el dashboard permite:

- Consultar KPIs de forma rápida
- Visualizar gráficos interactivos
- Comparar variables de negocio
- Entender patrones relevantes sin necesidad de revisar el código del análisis

De este modo, Streamlit se utilizó como una capa de presentación del proyecto, conectando el análisis técnico con una interfaz visual más accesible.

8.3. Principales métricas e indicadores

El dashboard incluye métricas clave que resumen el estado del negocio y facilitan su seguimiento. Entre las principales se encuentran:

Ventas

- Ingresos totales
- Número total de pedidos
- Ticket medio por pedido
- Evolución de ventas en el tiempo

Logística

- Tiempo medio de entrega
- Retraso medio de los pedidos
- Porcentaje de pedidos retrasados

Clientes

- Número total de clientes únicos
- Número de clientes recurrentes
- Porcentaje de recurrencia

Satisfacción

- Puntuación media de review
- Distribución de valoraciones de 1 a 5 estrellas

- Relación entre retraso y satisfacción

Estos indicadores permiten obtener una visión integral del negocio y detectar tanto fortalezas como posibles áreas de mejora.

8.1. Valor añadido y aplicación

El principal valor añadido del dashboard en Streamlit es que convierte un análisis técnico en una **herramienta visual, interactiva y fácilmente interpretable**.

Su aplicación práctica es especialmente útil porque:

- Facilita la comunicación de resultados a usuarios no técnicos
- Permite detectar patrones de forma rápida
- Mejora la presentación del proyecto frente a una entrega estática
- Ayuda a conectar el análisis exploratorio con una visión más aplicada al negocio

En este caso, el dashboard no solo sirve como apoyo visual, sino también como una demostración práctica de cómo los datos pueden convertirse en información útil para la toma de decisiones en áreas como ventas, logística, fidelización de clientes y satisfacción.

9. Contexto histórico de Olist y relación con los resultados

Entre 2016 y 2018, Brasil atravesaba una etapa de **recuperación económica tras una fuerte recesión (2014–2016)**. En este contexto, el e-commerce comenzó a crecer rápidamente, impulsado por el aumento del uso de internet y la necesidad de digitalización de muchos negocios.

Olist surge y crece en este entorno como una solución para **pequeños vendedores que querían acceder al canal online sin grandes inversiones**, posicionándose como intermediario entre estos y grandes marketplaces. Sin embargo, el país presentaba importantes **limitaciones logísticas**, como grandes distancias y desigualdad en infraestructuras, lo que afectaba directamente a los tiempos de entrega.

Este contexto se refleja claramente en los resultados del análisis:

- Se observa un **crecimiento progresivo de las ventas**, alineado con la expansión del e-commerce en Brasil
- La **baja recurrencia (~3%)** indica un mercado aún en desarrollo, con foco en captación más que en fidelización
- Los **tiempos de entrega elevados y retrasos** reflejan las dificultades logísticas del país y de un negocio en crecimiento
- La **satisfacción es alta**, pero disminuye cuando hay retrasos, mostrando el impacto directo de la logística
- La **concentración de ingresos en algunos clientes** es típica de una empresa en fase de consolidación

En conjunto, los resultados reflejan un negocio en expansión dentro de un mercado en crecimiento, pero condicionado por retos logísticos y de madurez del sector.

10. Resultados e insights clave

10.1. Hallazgos principales

- Existe un **crecimiento progresivo de las ventas**, especialmente en 2017 y 2018, lo que refleja la expansión del e-commerce en Brasil.
- La **recurrencia de clientes es baja (~3%)**, lo que indica que la mayoría de los clientes realizan compras puntuales y no repiten.
- El negocio presenta **dependencia de un grupo reducido de clientes**, que concentran una parte significativa de los ingresos.
- Los **tiempos de entrega son elevados (~12 días de media)**, con presencia de retrasos en una parte de los pedidos (~6,6%).
- La **satisfacción general es alta (4,08)**, pero con una distribución donde predominan las valoraciones de 5 estrellas, aunque existe un porcentaje relevante de valoraciones bajas.

10.2. Factores que influyen en la satisfacción del cliente

El análisis ha permitido identificar los principales factores que impactan en la experiencia del cliente:

- **Retrasos en la entrega (`delivery_delay`)**
  → Es el factor más determinante: a mayor retraso, menor puntuación.
- **Tiempo total de entrega (`delivery_time_days`)**
  → Entregas más rápidas están asociadas a mejores valoraciones.
- **Gestión logística**
  → Variaciones por ciudad y estado indican diferencias en la eficiencia operativa.
- **Valor del pedido**
  → Puede influir en la percepción del cliente, aunque con menor impacto que la logística.

En conjunto, la **logística se posiciona como el principal driver de la satisfacción del cliente**.

10.3. Posibles aplicaciones prácticas

Los resultados obtenidos pueden aplicarse directamente en un contexto de negocio:

- **Optimización logística**
  - Reducir tiempos de entrega
  - Minimizar retrasos
  - Mejorar la coordinación con transportistas
- **Mejora de la experiencia del cliente**
  - Identificar pedidos con riesgo de mala valoración
  - Aplicar medidas preventivas (comunicación, compensaciones)
- **Estrategias de fidelización**
  - Incentivar la repetición de compra
  - Programas de retención de clientes
- **Toma de decisiones basada en datos**

- Uso de dashboards para monitorizar KPIs
- Identificación de áreas críticas del negocio

- **Aplicación del modelo predictivo**
  - Anticipar la satisfacción del cliente
  - Detectar problemas antes de que ocurran

11. Conclusión

Este proyecto ha permitido analizar el negocio e-commerce de Olist de forma completa, desde la limpieza de datos hasta la visualización y modelado.

Los resultados muestran un negocio en crecimiento, con aumento de ventas, pero con áreas de mejora claras, especialmente en **logística y fidelización de clientes**. Se ha comprobado que los **retrasos en la entrega son el principal factor que reduce la satisfacción**, mientras que la recurrencia de clientes es baja.

Los dashboards en Power BI y Streamlit han permitido transformar el análisis en herramientas visuales útiles para la toma de decisiones.

En conjunto, el proyecto demuestra cómo el análisis de datos puede generar insights relevantes y aplicables en un contexto real de negocio.

12. Anexos

12.1. Fragmentos de código relevantes

Así es como se realicé el despliegue de streamlit

```
Anaconda Prompt - streamlit

(base) C:\Users\patri>conda activate hackio

(hackio) C:\Users\patri>cd "C:\Users\patri\OneDrive\Documentos\EDA-Final"

(hackio) C:\Users\patri\OneDrive\Documentos\EDA-Final>streamlit run .\dashboard\streamlit\dashboard.py

      Welcome to Streamlit!

      If you'd like to receive helpful onboarding emails, news, offers, promotions,
      and the occasional swag, please enter your email address below. Otherwise,
      leave this field blank.

      Email: romojimenezp@gmail.com

  You can find our privacy policy at https://streamlit.io/privacy-policy

  Summary:
  - This open source library collects usage statistics.
  - We cannot see and do not store information contained inside Streamlit apps,
    such as text, charts, images, etc.
  - Telemetry data is stored in servers in the United States.
  - If you'd like to opt out, add the following to %userprofile%/.streamlit/config.toml,
    creating that file if necessary:

    [browser]
    gatherUsageStats = false


  You can now view your Streamlit app in your browser.

  Local URL: http://localhost:8501
  Network URL: http://192.168.1.187:8501
```

13. Bibliografía y recursos utilizados

- Módulos de Python, Python for data y Regresión y Clasificación de Hack(io) by The Power
- Documentación oficial de Pandas: https://pandas.pydata.org/docs/user_guide/index.html
- Documentación oficial de Matplotly:

  https://matplotlib.org/stable/users/index

  https://seaborn.pydata.org/tutorial.html

- Documentación oficial de streamlit: https://docs.streamlit.io/
- Documentación oficial de XCBoost: https://xgboost.readthedocs.io/en/stable/python/python_intro.html